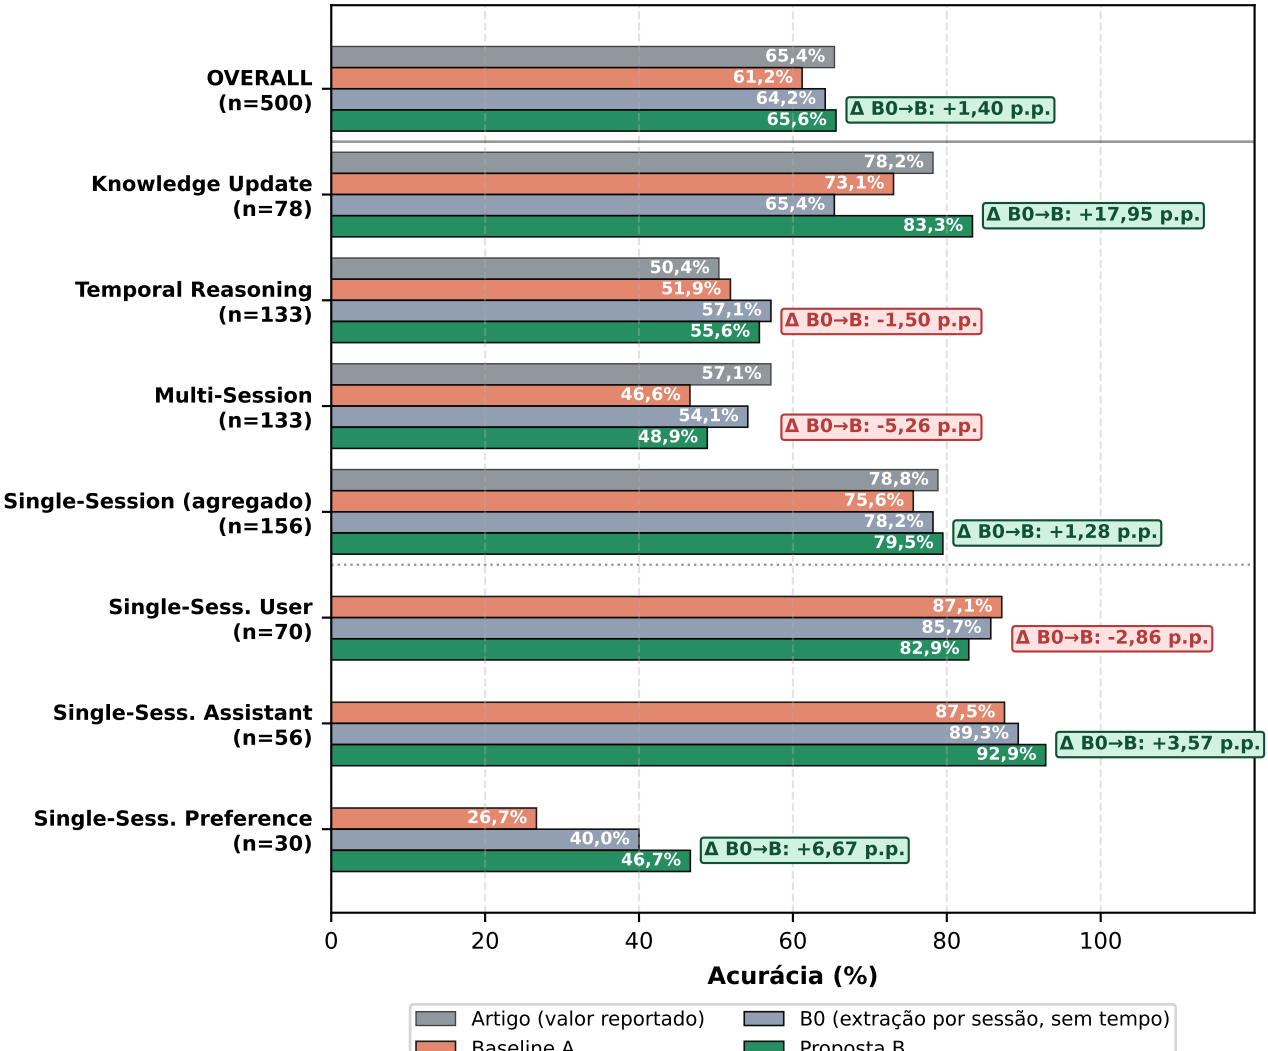
OVERALL
(n=500)
65,4%
61,2%
64,2%
65,6%
Δ B0→B: +1,40 p.p.
Knowledge Update
(n=78)
78,2%
73,1%
65,4%
83,3%
Δ B0→B: +17,95 p.p.
Temporal Reasoning
(n=133)
50,4%
51,9%
57,1%
55,6%
Δ B0→B: -1,50 p.p.
Multi-Session
(n=133)
57,1%
46,6%
54,1%
48,9%
Δ B0→B: -5,26 p.p.
Single-Session (agregado)
(n=156)
78,8%
75,6%
78,2%
79,5%
Δ B0→B: +1,28 p.p.
Single-Sess. User
(n=70)
87,1%
85,7%
82,9%
Δ B0→B: -2,86 p.p.
Single-Sess. Assistant
(n=56)
87,5%
89,3%
92,9%
Δ B0→B: +3,57 p.p.
Single-Sess. Preference
(n=30)
26,7%
40,0%
46,7%
Δ B0→B: +6,67 p.p.
0
20
40
60
80
100
Acurácia (%)
Artigo (valor reportado)
Baseline A
B0 (extração por sessão, sem tempo)
Proposta B