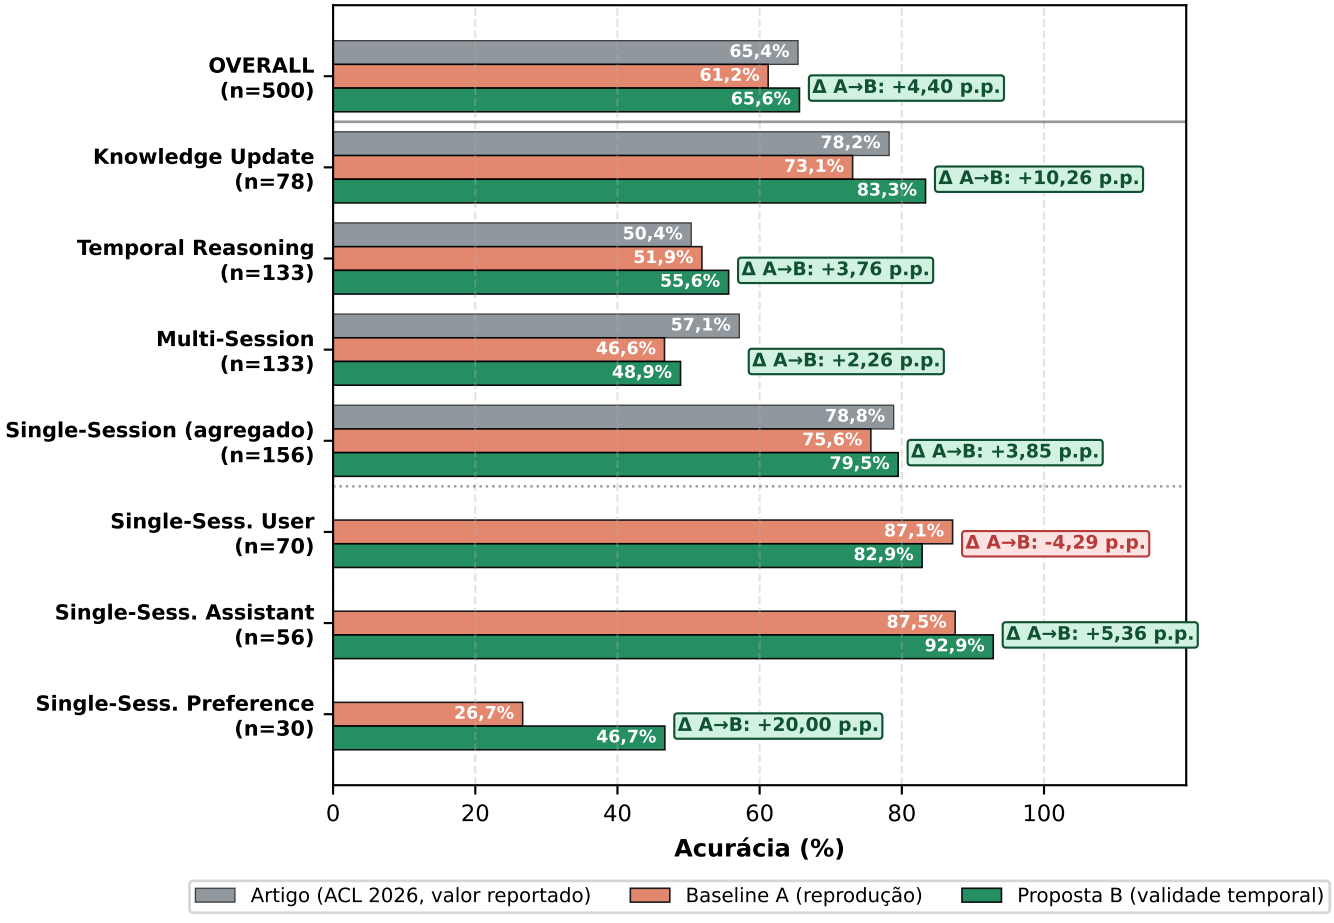
OVERALL (n=500)
65,4%
61,2%
65,6%
Δ A→B: +4,40 p.p.
Knowledge Update (n=78)
78,2%
73,1%
83,3%
Δ A→B: +10,26 p.p.
Temporal Reasoning (n=133)
50,4%
51,9%
55,6%
Δ A→B: +3,76 p.p.
Multi-Session (n=133)
57,1%
46,6%
48,9%
Δ A→B: +2,26 p.p.
Single-Session (agregado) (n=156)
78,8%
75,6%
79,5%
Δ A→B: +3,85 p.p.
Single-Sess. User (n=70)
87,1%
82,9%
Δ A→B: -4,29 p.p.
Single-Sess. Assistant (n=56)
87,5%
92,9%
Δ A→B: +5,36 p.p.
Single-Sess. Preference (n=30)
26,7%
46,7%
Δ A→B: +20,00 p.p.
0
20
40
60
80
100
Acurácia (%)
Artigo (ACL 2026, valor reportado)
Baseline A (reprodução)
Proposta B (validade temporal)